Quiz: Data Warehouse, Data Lake và Data Lakehouse

(Data Architecture)

Tác giả 1 **Tác giả 2**

Proofreading:

Mỗi câu hỏi có đúng một đáp án đúng. Các số liệu trong đề được lấy từ phần thực hành của bài đọc.

1. Một công ty lưu dữ liệu đơn hàng thành các file Parquet dưới prefix `s3://shop/orders/`. Spark và Trino đọc "bảng" `orders` bằng cách liệt kê mọi file dưới prefix này rồi tự suy ra schema. Hệ thống không có catalog hay transaction log nào. Theo tiêu chí "lớp nào sở hữu khái niệm bảng", đây là kiến trúc gì?

a) Data Warehouse, vì dữ liệu được lưu ở định dạng columnar.
b) Data Lakehouse, vì nhiều engine cùng đọc một bản dữ liệu.
c) Data Lake, vì không lớp nào sở hữu bảng; "bảng" chỉ là một prefix thư mục.
d) Data Lakehouse, vì footer của file Parquet đã chứa schema.

2. File `trips.parquet` có 4 row group. Footer cho biết khoảng giá trị của cột `fare_amount` trong từng row group: RG1 $[2, 45]$, RG2 $[3, 60]$, RG3 $[5, 480]$, RG4 $[1, 38]$. Với truy vấn `SELECT avg(tip_amount) FROM trips WHERE fare_amount > 100`, một engine hỗ trợ projection pushdown và predicate pushdown sẽ đọc những gì?

a) Cả 4 row group, đọc tất cả các cột.
b) Chỉ RG3, và chỉ hai cột `fare_amount`, `tip_amount`.
c) Chỉ RG3, nhưng đọc tất cả các cột.
d) Cả 4 row group, nhưng chỉ đọc cột `tip_amount`.

3. Một job upstream ghi nhầm một file có cột `VendorID` kiểu chuỗi vào cùng prefix của Data Lake, nơi các file khác đều lưu `VendorID` kiểu số nguyên. Lỗi này thường được phát hiện vào lúc nào?

a) Ngay lúc ghi, vì object storage kiểm tra schema của file.
b) Ngay lúc ghi, vì Parquet không cho ghi chuỗi vào một cột số.
c) Không bao giờ, vì engine tự bỏ qua các file sai kiểu.
d) Khi một engine quét prefix đó, thường là trong truy vấn của một người khác.

4. Một job ghi dữ liệu tháng 2 thành 4 file và bị dừng sau khi ghi xong file thứ hai. Một reader truy vấn ngay sau đó. Kết quả nào đúng?

a) Data Lake: reader thấy 2 file đã ghi mà không có cảnh báo. Iceberg: reader vẫn thấy snapshot cũ vì con trỏ trong catalog chưa đổi.

b) Data Lake: reader báo lỗi thiếu file. Iceberg: reader thấy 2 file đã ghi.

c) Cả hai đều thấy 2 file đã ghi, vì object storage có strong consistency.

d) Cả hai đều không thấy file nào, vì object storage chỉ hiển thị file khi job kết thúc.

5. Cho năm thành phần của một bảng Iceberg: (1) `snap-<id>.avro`, (2) `...-m0.avro`, (3) `00006-....metadata.json`, (4) `part-0.parquet`, (5) bản ghi của bảng trong catalog. Khi lập kế hoạch đọc bảng, engine đi qua chúng theo thứ tự nào?

a) (3) → (5) → (1) → (2) → (4)

b) (5) → (1) → (3) → (2) → (4)

c) (5) → (3) → (1) → (2) → (4)

d) (5) → (3) → (2) → (1) → (4)

6. Writer A và writer B cùng đọc metadata phiên bản 7 của một bảng Iceberg, rồi mỗi bên ghi data file mới vào một partition khác nhau. A commit trước và thành công, con trỏ giờ trỏ tới phiên bản 8. Điều gì xảy ra khi B commit?

a) B ghi đè phiên bản 8, dữ liệu của A bị mất.

b) Phép compare-and-swap của B thất bại vì con trỏ không còn là 7. B đọc phiên bản 8, thấy không xung đột, tạo phiên bản 9 chứa cả hai thay đổi rồi commit lại.

c) B bị chặn cho tới khi A trả lại khóa (lock) trên bảng.

d) Catalog tự gộp hai file `metadata.json` của A và B thành một.

7. Đoạn code PyIceberg sau chạy trên một catalog trống. Giả sử lệnh `delete` xóa ít nhất một dòng. Sau khi chạy xong, `tbl.snapshots()` có bao nhiêu snapshot?

Code

```
tbl = catalog.create_table("silver.trips", schema=schema)
tbl.append(jan)
with tbl.update_schema() as u:
    u.add_column("tip_per_mile", DoubleType())
with tbl.update_spec() as s:
    s.add_field("pickup_at", DayTransform(), "pickup_day")
tbl.append(feb)
tbl.delete(delete_filter=GreaterThan("fare_amount", 500.0))
```

a) 3

b) 4

c) 5
d) 6

8. Tiếp tục câu 7. Khi đọc các dòng tháng 1 (được ghi trước lệnh `add_column`), cột `tip_per_mile` có giá trị gì?

a) NULL, vì file tháng 1 không chứa field ID của cột mới và không bị ghi lại.
b) Giá trị được Iceberg tự tính từ `tip_amount` và `trip_distance`.
c) Truy vấn báo lỗi schema mismatch cho tới khi ghi lại toàn bộ bảng.
d) 0, vì Iceberg điền giá trị mặc định của kiểu double.

9. Một bảng Iceberg ban đầu không có partition và đang chứa 1 file dữ liệu tháng 1. Đội dữ liệu thêm partition `day(pickup_at)` rồi append dữ liệu tháng 2 (28 ngày). Nhận định nào đúng?

a) Iceberg tự ghi lại file tháng 1 thành 31 file theo ngày.
b) Muốn được partition pruning, truy vấn phải lọc trên cột `pickup_day`.
c) File tháng 1 bị loại khỏi snapshot hiện hành vì không khớp partition spec mới.
d) File tháng 1 giữ spec cũ (`spec_id` 0), file tháng 2 theo spec mới (`spec_id` 1); điều kiện trên `pickup_at` vẫn loại được file ở cả hai spec.

10. Bảng `orders` (2 TB) nhận dữ liệu CDC từ database vận hành: cứ 5 phút lại có vài nghìn lệnh `UPDATE` rải rác khắp bảng. Dashboard đọc bảng vài lần mỗi giờ. Chiến lược nào phù hợp nhất?

a) Copy-on-Write, vì đọc luôn nhanh nhất.
b) Ghi lại toàn bộ bảng sau mỗi 5 phút để không phải dùng delete file.
c) Merge-on-Read (delete file hoặc deletion vector), kết hợp compaction định kỳ.
d) Bỏ table format, ghi thẳng file mới vào Data Lake.

11. Dùng PyIceberg 0.12, đội dữ liệu chạy `expire_snapshots` chỉ giữ snapshot hiện hành, rồi thấy dung lượng thư mục `data/` không giảm. Giải thích nào đúng và cần làm gì tiếp?

a) Lệnh expire chưa được commit; chạy lại lệnh là đủ.
b) Expire chỉ xóa snapshot khỏi metadata. Các file không còn được tham chiếu đã thành orphan file và cần được dọn riêng, với ngưỡng thời gian đủ xa để không xóa nhầm file của job đang ghi.
c) Các file vẫn cần cho time travel về những snapshot đã expire nên không được xóa.
d) Cần chạy compaction thì dung lượng mới giảm.

12. Dữ liệu khách hàng đến từ CRM và ERP với địa chỉ mâu thuẫn nhau. Cần khử trùng lặp, chọn bản ghi đáng tin cậy và lưu lịch sử thay đổi địa chỉ theo SCD Type 2. Trong kiến trúc Medallion, việc này nên đặt ở lớp nào?

a) Silver
b) Bronze
c) Gold
d) Trong chính hệ thống CRM và ERP

13. `fact_trips` có 5.848.609 dòng. Sau khi `INNER JOIN` với `dim_payment_type` (không có điều kiện `WHERE`), kết quả chỉ còn 5.712.662 dòng. Nguyên nhân khả dĩ nhất và cách phát hiện là gì?

a) DuckDB làm tròn số khi JOIN; cần đổi sang kiểu `DECIMAL`.
b) Một số `payment_type_key` trong fact không có trong dimension (ví dụ mã 0) nên bị `INNER JOIN` loại; phát hiện bằng test khóa ngoại mồ côi (`LEFT JOIN ... WHERE dim.key IS NULL`).
c) Snapshot Iceberg đã thay đổi giữa hai truy vấn.
d) Dimension có dòng trùng khóa nên JOIN làm giảm số dòng.

14. Nhận định nào **không** phải là vấn đề của kiến trúc hai tầng (Data Lake + Data Warehouse) mà Armbrust và cộng sự nêu ra?

a) Dữ liệu trong warehouse trễ hơn nguồn hàng giờ đến hàng ngày.
b) Phải lưu hai bản dữ liệu và trả tiền compute cho ETL.
c) Thư viện ML khó đọc trực tiếp dữ liệu nằm trong warehouse.
d) Object storage không lưu được file Parquet.