Quiz: Data Sources; Data Ingestion Using Pyspark

Dương Nguyễn Thuận **Đinh Quang Vinh**

Proofreading: Nguyễn Lê Đức Tuệ, Huỳnh Kim Gia Bảo

Câu hỏi 1 : Trong quá trình thu thập dữ liệu, kịch bản nào sau đây bắt buộc phải sử dụng phương pháp Streaming Ingestion thay vì Batch Ingestion?

a) Hệ thống huấn luyện lại mô hình học máy định kỳ.

b) Hệ thống sao lưu dữ liệu theo tuần.

c) Hệ thống phát hiện gian lận giao dịch thẻ tín dụng.

d) Hệ thống báo cáo tài chính tổng hợp hàng tháng.

Câu hỏi 2 : Một 'Data Swamp' thường hình thành từ một Data Lake khi quản trị viên bỏ qua hoặc thiếu đi yếu tố cốt lõi nào sau đây?

a) Cơ chế quản trị và lập danh mục dữ liệu rõ ràng.

b) Khả năng mở rộng dung lượng lưu trữ phần cứng.

c) Băng thông mạng để truyền tải luồng dữ liệu lớn.

d) Khả năng tính toán của các vi xử lý trên máy chủ.

Câu hỏi 3 : Kỹ thuật Change Data Capture (CDC) trong kiến trúc Data Ingestion đóng vai trò chủ đạo là gì?

a) Thu thập và truyền tải các lệnh sửa đổi cơ sở dữ liệu.

b) Mã hóa toàn bộ khối dữ liệu trước khi lưu trữ xuống.

c) Chuyển đổi dữ liệu phi cấu trúc thành các bảng.

d) Nén dữ liệu để tiết kiệm tối đa không gian lưu trữ.

Câu hỏi 4 : Giả sử bạn có một PySpark DataFrame df chứa cột event_time mang kiểu dữ liệu chuỗi (String). Đoạn mã PySpark nào sau đây là cách chuẩn xác để tạo một DataFrame mới với cột này được ép kiểu sang Date?

a) df.modifyColumn("event_time", DateType())

b) df.select(convert_date("event_time").alias("date"))

c) df.withColumn("date", to_date(col("event_time")))

d) df.apply(lambda x: to_date(x["event_time"]))

Câu hỏi 5 : Dựa trên mô hình Lazy Evaluation của Apache Spark, hàm nào dưới đây của PySpark DataFrame được phân loại là một Action thay vì một Transformation?

a) df.count()

b) df.select("name", "salary")

c) df.filter(col("age") > 18)

d) df.groupBy("department")

Câu hỏi 6 : Tại sao kiến trúc ELT (Extract, Load, Transform) lại đặt bước Load trước khâu Transform, trái ngược với ETL truyền thống?

a) Để loại bỏ yêu cầu sử dụng ngôn ngữ SQL phân tích trong hệ thống

b) Để ép buộc các hệ thống nguồn tự biến đổi dữ liệu trước khi nạp đi.

c) Để loại bỏ hoàn toàn bước làm sạch và tinh chỉnh dữ liệu thô.

d) Để tận dụng sức mạnh tính toán khổng lồ của nền tảng kho dữ liệu đích.

Câu hỏi 7 : Cho đoạn mã **streamingDF.groupBy(window(col("timestamp"), "5 minutes", "2 minutes"))**. Ý nghĩa của hai tham số thời gian từ cấu hình 'window' là gì?

a) Cửa sổ tạo mới sau 5 phút và tự động xóa sau 2 phút.

b) Cửa sổ có độ trễ 5 phút và khoảng trượt đi là 2 phút.

c) Khoảng trượt dài 5 phút và độ rộng cửa sổ là 2 phút.

d) Cửa sổ lưu dữ liệu trong 5 phút và khoảng trượt là 2 phút.

Câu hỏi 8 : Khi đọc một file lưu trữ Parquet dung lượng 1TB bằng đoạn mã PySpark **df.filter(col("region") == "US")**, cơ chế 'Predicate Pushdown' của Spark hoạt động ra sao để tăng tốc truy vấn?

a) Spark đẩy điều kiện lọc xuống tầng lưu trữ, bỏ qua việc đọc vật lý các khối dữ liệu (blocks) không thuộc 'US'.

b) Spark gửi tín hiệu để nền tảng Hadoop nén dữ liệu lại 10 lần trước khi trả kết quả.

c) Spark tự động sinh ra một bảng chỉ mục B-Tree tạm thời trên ổ cứng của cluster trước khi lọc.

d) Spark vẫn tải toàn bộ 1TB dữ liệu vào RAM, nhưng phân công ưu tiên cho các máy chủ mạnh nhất để lọc.

Câu hỏi 9 : Trong hệ sinh thái Apache Spark, thành phần nào thực thi các quy tắc tối ưu hóa (như tự động gộp các bộ lọc kề nhau, hay đẩy điều kiện truy vấn xuống nơi lưu trữ) trên các DataFrame/SQL?

a) Spark Block Manager.

b) Project Tungsten.

c) Cluster Manager.

d) Catalyst Optimizer.

Câu hỏi 10 : Khi bạn gọi phương thức **df.cache()** trên một PySpark DataFrame, hệ thống sẽ sử dụng mức độ lưu trữ mặc định nào?

a) MEMORY_ONLY

b) DISK_ONLY

c) MEMORY_AND_DISK_SER

d) MEMORY_AND_DISK