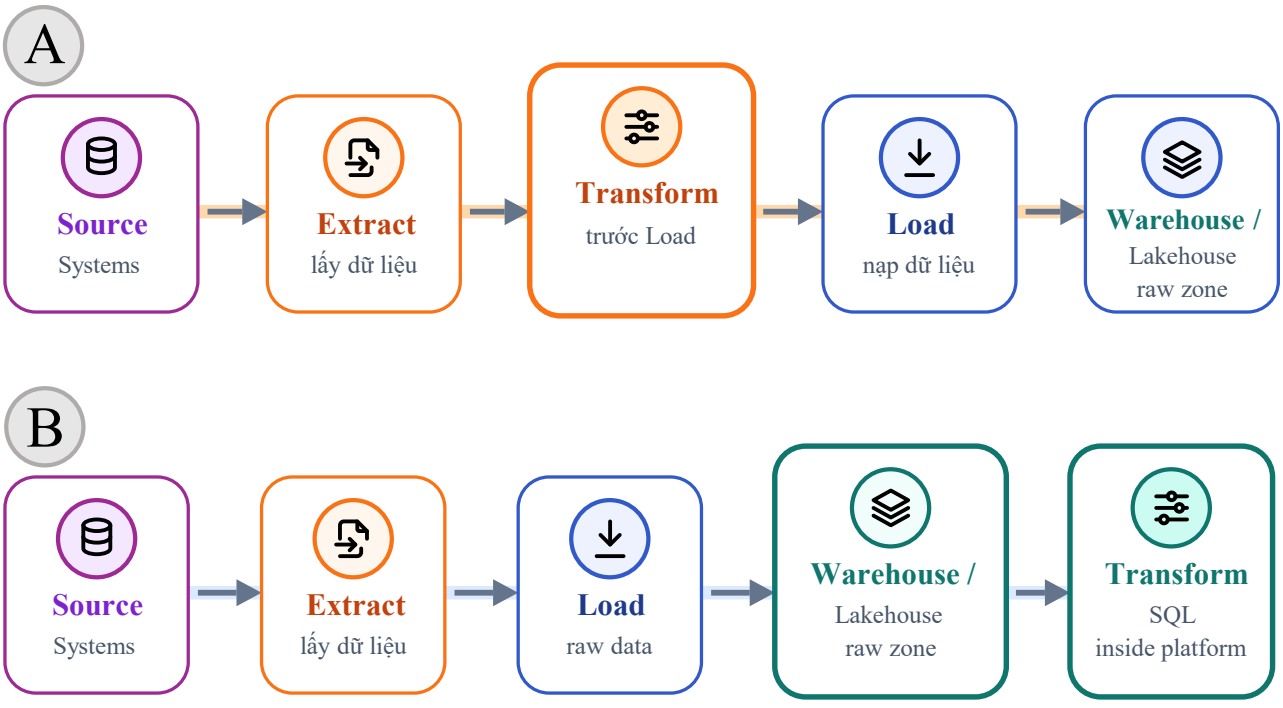
Quiz: Data Warehousing with Snowflake

Nguyễn Đăng Nhã **Trần Quang Minh** **Đinh Quang Vinh**

Proofreading: Phạm Tiến

1. Một công ty đang xây dựng pipeline để đưa dữ liệu từ các hệ thống vận hành vào nền tảng phân tích. Data team đang cân nhắc hai cách tổ chức thứ tự xử lý dữ liệu khác nhau.



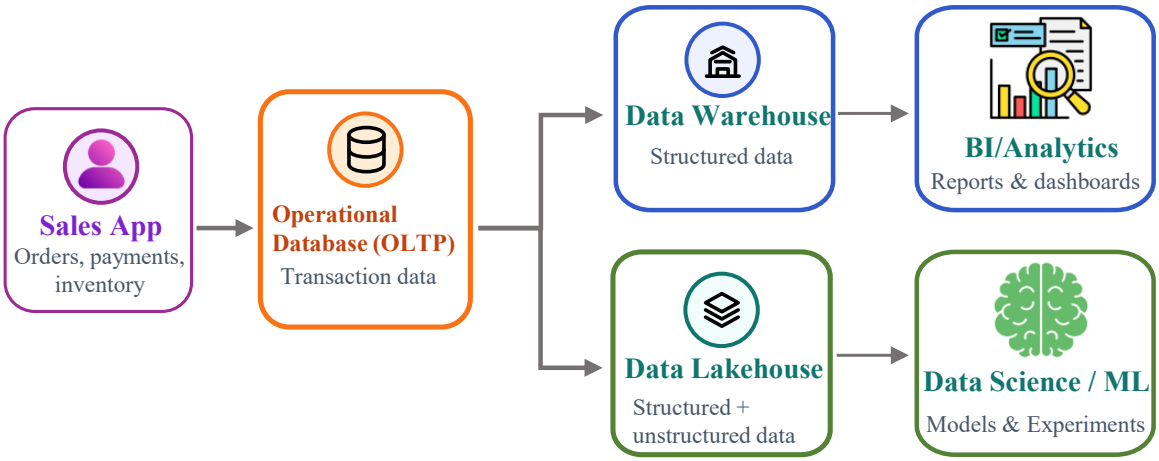
Hình 1: Hai cách tổ chức thứ tự Extract, Transform và Load.

Dựa trên Hình 1, pipeline nào thể hiện quy trình ELT?

a) Pipeline A, vì dữ liệu được Transform trước khi Load vào hệ thống đích.
b) Cả hai pipeline đều là ELT vì đều có đủ các bước Extract, Load và Transform.
c) Pipeline B, vì dữ liệu được Load vào hệ thống đích trước rồi mới Transform.
d) Không pipeline nào là ELT vì cả hai đều bắt đầu bằng bước Extract.

2. Một công ty bán lẻ dùng ứng dụng để ghi nhận đơn hàng, thanh toán và cập nhật tồn kho mỗi ngày. Database phía sau ứng dụng cần xử lý liên tục các thao tác như thêm đơn hàng mới, thay đổi trạng thái thanh toán hay cập nhật số lượng sản phẩm.

   Sau một thời gian, công ty muốn sử dụng dữ liệu đã tích lũy để trả lời những câu hỏi rộng hơn như doanh thu thay đổi theo tháng, khu vực nào bán tốt hơn hay xu hướng của từng nhóm sản phẩm.



Hình 2: Từ hệ thống vận hành đến Data Warehouse và Data Lakehouse.

   Nhận định nào mô tả đúng nhất vai trò của hai hệ thống trong trường hợp này?

   a) OLTP phục vụ dữ liệu đang được ứng dụng sử dụng, còn Data Warehouse giữ một bản sao của dữ liệu để tránh ảnh hưởng đến database ban đầu.

   b) OLTP phù hợp với các truy vấn đơn giản, còn Data Warehouse phù hợp với các truy vấn có nhiều bảng và phép tính phức tạp.

   c) OLTP (xử lý giao dịch trực tuyến) được tối ưu cho việc ghi nhận và cập nhật nhiều giao dịch nhỏ, còn Data Warehouse (kho dữ liệu) tổ chức dữ liệu từ nhiều thời điểm để thuận tiện cho các truy vấn tổng hợp và phân tích.

   d) OLTP lưu dữ liệu chi tiết của từng giao dịch, còn Data Warehouse chủ yếu lưu kết quả đã được tổng hợp sẵn để tạo báo cáo.

3. Trong Hình 2, Data Warehouse được sử dụng để chuẩn bị dữ liệu cho báo cáo và phân tích. Khi nhu cầu mở rộng, doanh nghiệp có thể muốn giữ nhiều dạng dữ liệu hơn và sử dụng cùng nguồn dữ liệu đó cho cả báo cáo lẫn Data Science (khoa học dữ liệu) và Machine Learning (học máy).

   Nhận định nào mô tả đúng nhất ý tưởng của Data Lakehouse (kiến trúc kết hợp Data Lake và Data Warehouse)?

   a) Dùng Data Lake cho Data Science và Machine Learning, còn các bảng phục vụ báo cáo vẫn được chuyển sang một Data Warehouse riêng.

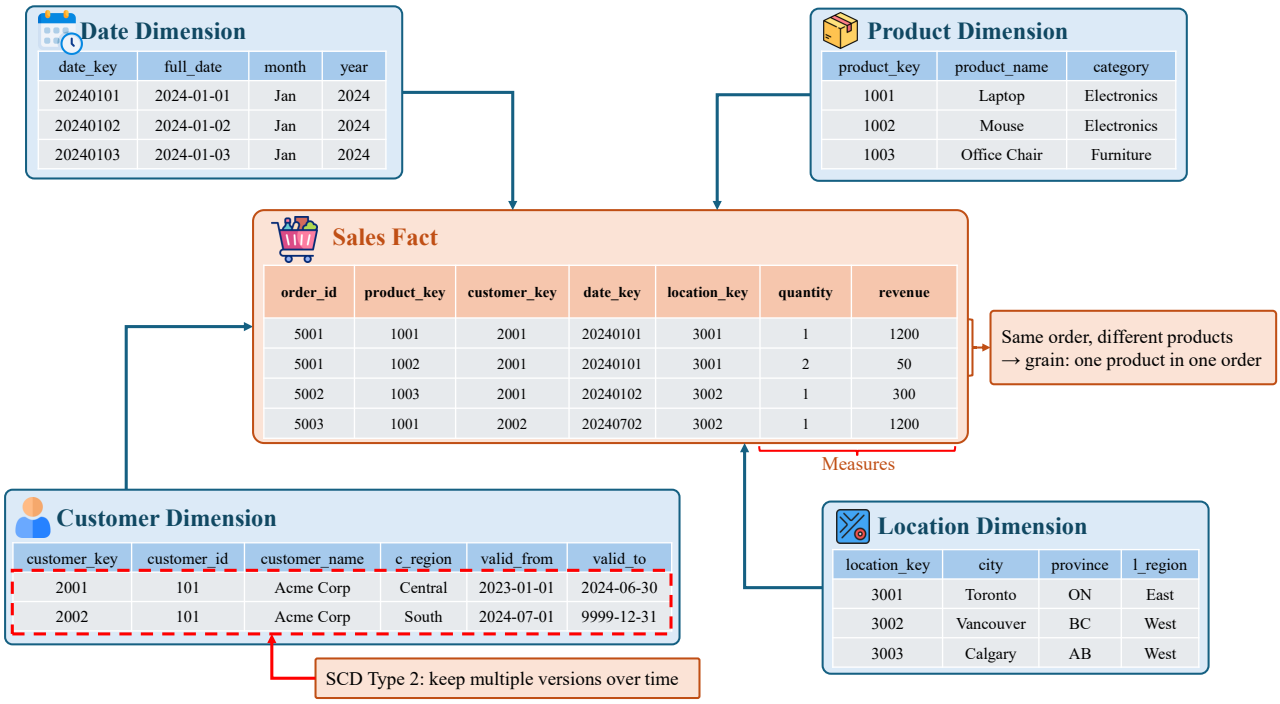
b) Giữ khả năng lưu trữ linh hoạt của Data Lake (hồ dữ liệu), đồng thời bổ sung cách tổ chức và quản lý dữ liệu để hỗ trợ những nhu cầu phân tích vốn thường được thực hiện trên Data Warehouse.

c) Sử dụng Data Lake làm nơi lưu dữ liệu gốc và Data Warehouse làm nơi chứa dữ liệu đã xử lý, sau đó kết nối hai hệ thống thành một Data Lakehouse.

d) Mở rộng Data Warehouse để có thể lưu thêm dữ liệu không có cấu trúc, trong khi cách quản lý và truy vấn dữ liệu về cơ bản vẫn giống Data Warehouse truyền thống.

4. Đội dữ liệu đang chuẩn bị dữ liệu bán hàng để trả lời các câu hỏi như "Doanh thu là bao nhiêu?", "Bán được bao nhiêu sản phẩm?", đồng thời cần xem các kết quả đó theo sản phẩm, khách hàng, thời gian và khu vực.

   Để phục vụ những câu hỏi này, dữ liệu được tổ chức theo Star Schema (mô hình sao). Một bảng trung tâm ghi nhận các sự kiện bán hàng và các giá trị cần đo, còn các bảng xung quanh chứa thông tin dùng để lọc, nhóm hoặc so sánh kết quả theo từng chiều như sản phẩm, khách hàng, thời gian và địa điểm.



Hình 3: Star Schema cho dữ liệu bán hàng.

Nhận định nào mô tả đúng nhất vai trò của Fact (bảng sự kiện) và Dimension (bảng chiều) trong mô hình ở Hình 3?

a) Sales Fact tập trung vào dữ liệu phát sinh trong quá khứ, còn các Dimension chỉ phản ánh trạng thái mới nhất của dữ liệu.

b) Sales Fact và Dimension chứa cùng loại thông tin, nhưng được tách thành nhiều bảng để giảm số lượng dữ liệu trong mỗi bảng.

c) Sales Fact lưu đầy đủ thông tin về sản phẩm, khách hàng và địa điểm, còn các Dimension chủ yếu lưu những kết quả đã được tổng hợp.

d) Sales Fact lưu các giá trị cần đo như `quantity`, `revenue` cùng các khóa liên kết, còn các Dimension chứa thông tin như tên sản phẩm, khách hàng, tháng hoặc khu vực để lọc và nhóm các giá trị đó.

5. Khi lưu dữ liệu bán hàng, cùng một đơn hàng có thể chứa nhiều sản phẩm và mỗi sản phẩm lại có số lượng hoặc doanh thu riêng. Vì vậy trước khi thiết kế Sales Fact, đội dữ liệu cần xác định rõ "một dòng trong bảng này đang đại diện cho toàn bộ đơn hàng, một sản phẩm trong đơn hàng hay dữ liệu đã được tổng hợp theo một khoảng thời gian nào đó?".

   Quyết định này được gọi là grain (mức chi tiết của một dòng dữ liệu). Grain trả lời câu hỏi "một dòng trong Fact Table đại diện cho sự kiện kinh doanh nào?". Chẳng hạn, ở mức giao dịch, một dòng có thể đại diện cho một sản phẩm trong một đơn hàng tại một thời điểm cụ thể. Nếu dữ liệu được tổng hợp theo ngày, một dòng có thể đại diện cho tổng doanh số của một sản phẩm trong cả ngày đó.

   Quan sát các dòng trong Sales Fact (bảng sự kiện bán hàng) ở Hình 3. Grain phù hợp nhất của bảng này là gì?

   a) Một dòng đại diện cho một sản phẩm xuất hiện trong một đơn hàng.

   b) Một dòng đại diện cho tổng doanh thu của một sản phẩm trong một tháng.

   c) Một dòng đại diện cho toàn bộ một đơn hàng, dù đơn hàng có thể chứa nhiều sản phẩm.

   d) Một dòng đại diện cho tổng hoạt động mua hàng của một khách hàng trong một ngày.

6. Sau khi dữ liệu bán hàng đã được tổ chức, đội kinh doanh thường không chỉ hỏi "Doanh thu là bao nhiêu?" mà còn muốn xem doanh thu theo tháng, khu vực, sản phẩm hoặc khách hàng. Khi đó, một truy vấn cần kết hợp số liệu bán hàng với các thuộc tính dùng để nhóm hoặc lọc kết quả.

   Trong Star Schema (mô hình sao), Fact được nối trực tiếp với các Dimension chứa những thuộc tính này. Vì vậy, để tính chẳng hạn "doanh thu theo region và month", truy vấn có thể đi từ Sales Fact trực tiếp sang Location Dimension và Date Dimension thay vì phải lần lượt đi qua nhiều bảng trung gian.

   Dựa trên mô hình trong Hình 3, điểm nào mô tả đúng nhất lợi ích của cách tổ chức này?

   a) Các kết quả như doanh thu theo tháng hay theo khu vực đã được tính sẵn nên người dùng hầu như không cần nối dữ liệu giữa các bảng.

   b) Tất cả thông tin về thời gian, sản phẩm, khách hàng và khu vực được đưa vào Fact để mỗi câu hỏi chỉ cần đọc một bảng.

   c) Các giá trị cần đo nằm ở Fact, còn các thuộc tính dùng để lọc và nhóm dữ liệu nằm trong những Dimension được liên kết trực tiếp với Fact.

   d) Số lượng dữ liệu trong Star Schema luôn ít hơn các cách tổ chức khác nên mọi truy vấn đều có thời gian chạy ngắn hơn.

7. Thông tin mô tả một khách hàng không phải lúc nào cũng giữ nguyên. Chẳng hạn Customer 101 thuộc khu vực Central trong năm 2025 nhưng chuyển sang South từ năm 2026.

   Nếu chỉ thay Central bằng South, khi xem lại báo cáo năm 2025, các giao dịch cũ cũng sẽ bị gắn với South. Trong khi đó, doanh nghiệp muốn giao dịch năm 2025 vẫn thuộc Central và các giao dịch từ năm 2026 mới thuộc South.

   Cách xử lý nào phù hợp nhất với yêu cầu này?

   a) Khi khách hàng đổi khu vực, cập nhật lại các giao dịch cũ để toàn bộ lịch sử sử dụng cùng một khu vực.

   b) Lưu lại nhiều phiên bản của khách hàng và ghi rõ khoảng thời gian mỗi phiên bản có hiệu lực, để giao dịch cũ vẫn liên kết với thông tin đúng tại thời điểm xảy ra.

   c) Bỏ thông tin khu vực khỏi Customer Dimension và chỉ lưu khu vực trực tiếp trong mỗi giao dịch bán hàng.

   d) Chỉ giữ thông tin mới nhất của khách hàng và sử dụng nó cho toàn bộ giao dịch ở cả hiện tại lẫn quá khứ.

8. Thông tin mô tả khách hàng có thể thay đổi theo thời gian. Ví dụ, cùng một khách hàng có thể thuộc khu vực Central trong giai đoạn trước rồi chuyển sang South từ một thời điểm mới. Nếu chỉ ghi đè giá trị mới nhất, các báo cáo của những năm trước cũng sẽ bị thay đổi theo.

   Trong Hình 3, Customer Dimension (bảng chiều khách hàng) lưu nhiều phiên bản của cùng một khách hàng và kèm khoảng thời gian mỗi phiên bản có hiệu lực. Cách làm này giúp hệ thống biết giao dịch nào cần gắn với thông tin cũ và giao dịch nào cần gắn với thông tin mới.

   Cách xử lý này nhằm mục đích gì?

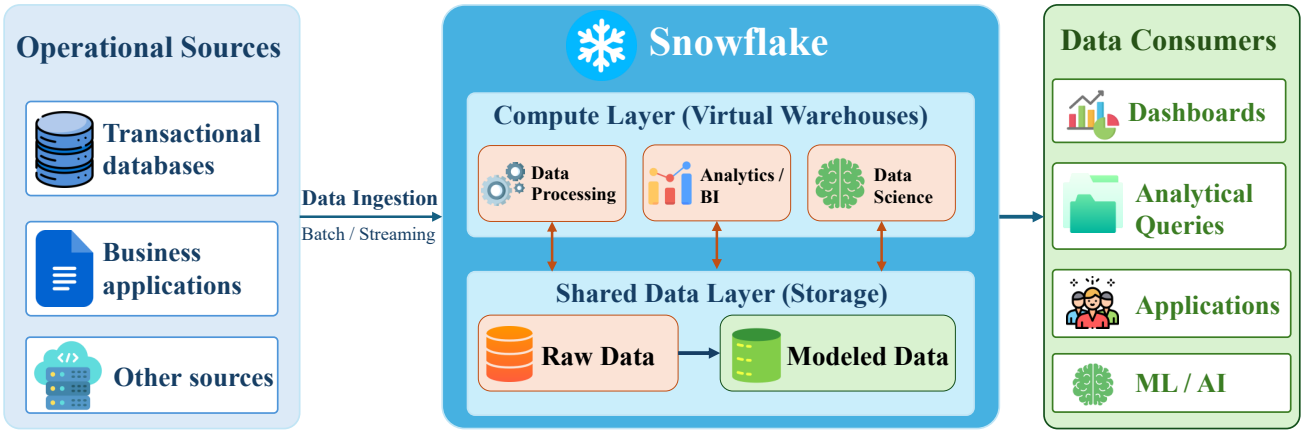
   a) Chuyển toàn bộ thông tin khách hàng vào Sales Fact để không cần quản lý Customer Dimension theo thời gian.

   b) Tạo nhiều bản ghi cho cùng một khách hàng chủ yếu để giảm số lượng phép nối khi chạy truy vấn.

   c) Đảm bảo mỗi khách hàng chỉ có một bản ghi mới nhất để toàn bộ báo cáo luôn dùng cùng một khu vực.

   d) Giữ lại lịch sử thay đổi để mỗi giao dịch vẫn được phân tích theo thông tin có hiệu lực tại thời điểm nó xảy ra.

9. Khi dữ liệu đã được đưa vào Snowflake, nhiều nhóm có thể sử dụng cùng lúc. Data Engineer có thể đang xử lý và biến đổi dữ liệu, trong khi đội BI vẫn cần chạy dashboard và các truy vấn phân tích.



Hình 4: Kiến trúc Snowflake với Compute Layer và Shared Data Layer.

Trong Hình 4, các nhóm này dùng Virtual Warehouse (cụm tài nguyên tính toán) khác nhau nhưng cùng truy cập Shared Data Layer (lớp dữ liệu dùng chung).

Lợi ích nào mô tả đúng nhất cách tổ chức này?

a) Các workload có thể dùng compute riêng trên cùng dữ liệu, nhờ đó một workload nặng không bắt buộc phải tranh chấp tài nguyên tính toán với workload khác.

b) Vì dữ liệu đã nằm trong Storage nên các truy vấn phân tích không cần sử dụng tài nguyên tính toán.

c) Khi một Virtual Warehouse dừng hoạt động, phần dữ liệu mà warehouse đó sử dụng cũng bị xóa khỏi Snowflake.

d) Mỗi Virtual Warehouse phải lưu một bản sao riêng của toàn bộ dữ liệu để có thể hoạt động độc lập.

10. Một doanh nghiệp có dữ liệu từ các hệ thống vận hành như transactional database và business application. Thay vì biến đổi toàn bộ dữ liệu trước khi đưa vào nền tảng phân tích, dữ liệu được nạp vào Snowflake ở dạng raw trước, sau đó mới được xử lý thành dữ liệu đã được mô hình hóa để phục vụ báo cáo, truy vấn phân tích và các nhu cầu khác.

    Dựa trên toàn bộ flow trong Hình 4, phương án nào mô tả đúng nhất cách hệ thống này hoạt động?

    a) Dữ liệu từ hệ thống vận hành được đưa thẳng đến dashboard và Machine Learning mà không cần qua bước lưu trữ hay biến đổi trong Snowflake.

    b) Dữ liệu được Transform trước khi Load vào Snowflake, sau đó mỗi nhóm phải lưu một bản dữ liệu riêng để sử dụng.

    c) Dữ liệu được Load vào Snowflake trước, sau đó Transform thành modeled data, còn các workload khác nhau có thể dùng Virtual Warehouse riêng trên cùng lớp dữ liệu.

    d) Raw Data và Modeled Data được lưu trong các Virtual Warehouse khác nhau, còn Storage chỉ dùng để giữ metadata.